

大语言模型部署体验报告

学号： 2454301

姓名： 朱林瀚

项目公开可访问链接： <https://github.com/2454301/AI-hw3.git>

一、部署环境与模型下载

本次实验在阿里云 ModelScope（魔搭）平台进行，使用免费 CPU 计算实例（8 核 32GB 内存）。按照教程指引，启动 Jupyter Notebook 环境，进入 Terminal 终端，安装 PyTorch CPU 版、transformers、modelscope 等基础依赖。随后通过 git clone 命令下载了两个大语言模型到/mnt/data 目录：

通义千问 Qwen-7B-Chat（阿里云，参数量 7B，约 14GB）；

智谱 ChatGLM3-6B（智谱 AI，参数量 6B，约 12GB）。

部署完成截图如下：

```
root@dsw-1900643-6bb49dc547-wwkfj:/mnt/data# git clone https://www.modelscope.cn/qwen/Qwen-7B-Chat.git
正克隆到 'Qwen-7B-Chat'...
remote: Enumerating objects: 554, done.
remote: Counting objects: 100% (56/56), done.
remote: Compressing objects: 100% (30/30), done.
remote: Total 554 (delta 30), reused 49 (delta 26), pack-reused 498
接收对象中: 100% (554/554), 16.47 MiB | 33.00 MiB/s, 完成.
处理 delta 中: 100% (295/295), 完成.
过滤内容: 100% (8/8), 14.38 GiB | 151.25 MiB/s, 完成.

root@dsw-1900643-6bb49dc547-wwkfj:/mnt/workspace# git clone https://www.modelscope.cn/ZhipuAI/chatglm3-6b.git
正克隆到 'chatglm3-6b'...
remote: Enumerating objects: 147, done.
remote: Counting objects: 100% (46/46), done.
remote: Compressing objects: 100% (39/39), done.
remote: Total 147 (delta 20), reused 19 (delta 6), pack-reused 101
接收对象中: 100% (147/147), 77.54 KiB | 547.00 KiB/s, 完成.
处理 delta 中: 100% (62/62), 完成.
过滤内容: 100% (15/15), 23.26 GiB | 152.80 MiB/s, 完成.
```

二、问答测试与结果

依据作业“补充材料 2”中的建议，选取两个典型的中文歧义句/双关句进行

测试。

3.1 问题 1

测试模型： 通义千问 Qwen-7B-Chat

模型输出截图：

```
Loading checkpoint shards: 100%|
请说出以下两句话区别在哪里?1、冬天:能穿多少穿多少2、夏天:能穿多少穿多少

这两句话的区别在于,它们强调的是在不同季节如何穿衣的建议。

第一句话“冬天:能穿多少穿多少”是在提醒人们冬季天气寒冷,需要多穿衣服来保暖。这句话的目的是为了防止因为穿着不够而感冒或者感到冷。

第二句话“夏天:能穿多少穿多少”是在提醒人们夏季天气炎热,需要适当减少衣物以保持凉爽。这句话的目的是为了防止因为穿着过多而导致中暑或者出汗过多。

总的来说,这两句话都是在提醒人们根据不同的季节和天气条件来调整自己的衣着,但侧重点不同。<|endoftext|>
```

(内容:

这两句话的区别在于,它们强调的是在不同季节如何穿衣的建议。

第一句话 冬天:能穿多少穿多少是在提醒人们冬季天气寒冷,需要多穿衣服来保暖。这句话的目的是为了防止因为穿着不够而感冒或者感到冷。

第二句话 夏天:能穿多少穿多少是在提醒人们夏季天气炎热,需要适当减少衣物以保持凉爽。这句话的目的是为了防止因为穿着过多而导致中暑或者出汗过多。

总的来说,这两句话都是在提醒人们根据不同的季节和天气条件来调整自己的衣着,但侧重点不同。)

3.2 问题 2

测试模型： 智谱 ChatGLM3-6B

模型输出截图：

```
Loading checkpoint shards: 100%|
[QWEN]sep 2. 请说出以下两句话区别在哪里? 单身狗产生的原因有两个, 一是谁都看不上, 二是谁都看不上。
这两句话的区别在于, 第一句“单身狗产生的原因有两个, 一是谁都看不上, 二是谁都看不上。”中, 使用了两个“谁”来表示看不上的人, 强调的是看不上的人很多, 而第二句“单身狗产生的原因有两个, 一是谁都看不上, 二是没有找到合适的伴侣。”中, 则使用“没有找到合适的伴侣”来解释单身狗的原因, 突出了找不到合适的伴侣这个因素。
```

(内容:

这两句话的区别在于,第一句“单身狗产生的原因有两个,一是谁都看不上,二是谁都看不上。”中,使用了两个“谁”来表示看不上的人,强调的是看不上的人很多,而第

二句单身狗产生的原因有两个,一是谁都看不上,二是没有找到合适的伴侣。”中,则是用没有找到合适的伴侣”来解释单身狗的原因,突出了找不到合适的伴侣这个因素。)

三、模型横向对比分析

3.1 中文歧义句理解能力

在问题 1 中, Qwen-7B-Chat 准确识别了“能穿多少穿多少”在冬夏两季的相反含义: 冬天多穿保暖, 夏天少穿纳凉, 并分别解释目的, 最终总结核心差异。这表明模型能结合季节语境动态解读语义, 具备较强的语用推理能力。

在问题 2 中, ChatGLM3-6B 未能清晰区分两个“谁都看不上”的双重含义(第一个指“自己看不上别人”, 第二个指“别人看不上自己”)。回答中出现重复句子、逻辑不够紧密的情况, 说明其在需要深层次逻辑分解的双关句上解析能力相对有限。从问题 1 的表现推测, Qwen 更擅长先分解句子结构再分点回答, 可能在类似问题上表现更优。

3.2 回答完整性与逻辑组织

Qwen 采用“总—分—总”结构: 先点明季节差异, 再分别说明冬夏建议, 最后总结。回答层次分明、语言流畅, 体现了生成连贯、有组织长文本的能力。ChatGLM 的回答则较为啰嗦, 部分内容直接复制题目中的句子, 缺少有效的重组和提炼, 逻辑清晰度不如 Qwen。

3.3 推理速度与资源占用

两个模型在 CPU 环境下加载时间相近: Qwen 内存占用约 14GB, ChatGLM 约 12GB, 加载完成各需 15–20 秒。生成 200–300 token 的回答需 1–2

分钟。免费 CPU 实例算力有限，但足以完成基本推理。ChatGLM 在内存占用上略占优势，更适合资源紧张的环境。

3.4 适用场景总结

通义千问 Qwen-7B-Chat：适合需要高质量中文对话、对回答结构有要求的场景（如教育问答、内容生成、复杂指令理解），在语义理解和回答完整性上表现更优。

智谱 ChatGLM3-6B：内存占用略低、中文对话流畅，适合资源受限的边缘设备或简单闲聊场景，但对精确逻辑拆解的任务需谨慎使用。

四、实验总结

成功在 ModelScope 平台上部署两个 7B 级中文大语言模型，并完成歧义句测试。完整经历了环境配置、依赖安装、模型下载、推理测试和结果分析的全流程。主要收获包括：掌握基于 Hugging Face Transformers 加载开源大模型的标准流程；学会在 CPU 环境下优化内存使用（限制生成长度、使用量化模型等）；理解不同中文大模型在语义理解、逻辑推理上的能力差异。